



Université Abderrahmane Mira de Béjaïa

Faculté des Sciences Exactes

Département d'Informatique

RAPPORT DE PROJET

Détection précoce de la maladie d'Alzheimer à partir d'IRM

Master 1 — Module : Big Data

Réalisé par :

Mazouzi Célia

Zehnati Alicia

Talbi Lynda

Mohamadi Mounia

Radjeb Zahra

Encadrée par :

Mme El bouhissi

Mlle Illoul

Année Universitaire 2025/2026

Table des matières

1	Introduction	3
1.1	Contexte	3
1.2	Problématique	3
1.3	Objectifs du projet	3
1.4	Organisation du rapport	4
2	Notions Théoriques	5
2.1	La maladie d'Alzheimer	5
2.1.1	Définition	5
2.1.2	Les stades de la maladie	5
2.2	L'IRM cérébrale	6
2.2.1	Définition	6
2.2.2	L'IRM dans le diagnostic d'Alzheimer	6
2.3	Big Data et Hadoop	6
2.3.1	Définition du Big Data	6
2.3.2	Apache Hadoop	6
2.3.3	Apache Spark	7
2.4	Machine Learning et Deep Learning	7
2.4.1	Machine Learning	7
2.4.2	Deep Learning	7
2.5	Les Réseaux de Neurones Convolutifs (CNN)	7
3	Solution Proposée	9
3.1	Architecture du système	9
3.2	Dataset utilisé	9
3.3	Prétraitement des données	10
3.4	Modèle CNN	10
3.4.1	Architecture du modèle	10
3.4.2	Paramètres d'entraînement	10
3.5	Déploiement sur Hadoop via PySpark	11
3.5.1	Pipeline de déploiement	11

3.5.2	Analyse Big Data avec Spark	11
3.6	Interface utilisateur Gradio	11
4	Résultats et Évaluation	13
4.1	Résultats de l'entraînement	13
4.2	Évaluation finale du modèle	14
4.3	Matrice de confusion	14
4.4	Analyse Big Data avec Spark	15
4.5	Démonstration de l'interface Gradio	15
5	Conclusion	16
	Bibliographie	17

1. Introduction

1.1 Contexte

La maladie d'Alzheimer est l'une des maladies neurodégénératives les plus répandues dans le monde. Elle touche plus de 55 millions de personnes à travers le globe, et ce nombre devrait tripler d'ici 2050 selon l'Organisation Mondiale de la Santé (OMS). Cette maladie provoque une dégradation progressive des fonctions cognitives, affectant la mémoire, le langage et le comportement, conduisant à une perte totale d'autonomie.

L'un des défis majeurs dans la lutte contre cette maladie est sa détection tardive. En effet, les symptômes cliniques n'apparaissent souvent qu'à un stade avancé, lorsque les dommages cérébraux sont déjà irréversibles. La détection précoce représente donc un enjeu crucial pour permettre une prise en charge médicale adaptée et ralentir la progression de la maladie.

1.2 Problématique

Comment peut-on exploiter les technologies du Big Data et de l'Intelligence Artificielle pour détecter automatiquement et précocement la maladie d'Alzheimer à partir d'images IRM cérébrales, et déployer ce système de prédiction sur une infrastructure Hadoop ?

1.3 Objectifs du projet

Ce projet vise à atteindre les objectifs suivants :

- Implémenter un système de prédiction automatique du stade de la maladie d'Alzheimer à partir d'images IRM cérébrales.
- Utiliser des algorithmes de Deep Learning, notamment les Réseaux de Neurones Convolutifs (CNN), pour la classification des images médicales.
- Déployer le système sur une infrastructure Big Data basée sur Apache Hadoop et Apache Spark.

- Développer une interface utilisateur intuitive permettant aux professionnels de santé d'utiliser le système facilement.
- Évaluer les performances du modèle selon des métriques reconnues : précision, recall et F1-score.

1.4 Organisation du rapport

Ce rapport est organisé comme suit : la section 2 présente les notions théoriques relatives au thème choisi. La section 3 décrit en détail la solution proposée. La section 4 présente et analyse les résultats obtenus. Enfin, la section 5 conclut le rapport et propose des perspectives futures.

2. Notions Théoriques

2.1 La maladie d'Alzheimer

2.1.1 Définition

La maladie d'Alzheimer est une maladie neurodégénérative progressive qui détruit lentement la mémoire et les capacités de réflexion. Elle est la cause la plus fréquente de démence chez les personnes âgées. Sur le plan neurologique, elle est caractérisée par l'accumulation de plaques amyloïdes et de dégénérescences neurofibrillaires dans le cerveau, entraînant la mort progressive des neurones.

2.1.2 Les stades de la maladie

La maladie d'Alzheimer évolue généralement en plusieurs stades progressifs. Notre système de prédiction classe les images IRM en quatre catégories correspondant à ces stades :

Classe	Stade	Description
NonDemented	Sain	Aucun signe de démence. Fonctions cognitives normales.
VeryMildDemented	Très léger	Signes très légers. Légères pertes de mémoire occasionnelles.
MildDemented	Léger	Difficultés cognitives notables affectant la vie quotidienne.
ModerateDemented	Modéré	Dépendance accrue. Nécessite une assistance quotidienne.

TABLE 2.1 – Les stades de la maladie d'Alzheimer

2.2 L'IRM cérébrale

2.2.1 Définition

L'Imagerie par Résonance Magnétique (IRM) est une technique d'imagerie médicale non invasive qui permet d'obtenir des images détaillées des structures internes du cerveau. Contrairement aux rayons X, l'IRM n'utilise pas de rayonnements ionisants, ce qui en fait une technique sûre pour le patient.

2.2.2 L'IRM dans le diagnostic d'Alzheimer

Dans le contexte de la maladie d'Alzheimer, l'IRM permet de visualiser l'atrophie cérébrale, particulièrement dans l'hippocampe, région du cerveau impliquée dans la mémorisation. Les images IRM révèlent une réduction progressive du volume cérébral corrélée à l'avancement de la maladie, ce qui en fait un outil diagnostique précieux.

2.3 Big Data et Hadoop

2.3.1 Définition du Big Data

Le Big Data désigne des ensembles de données dont le volume, la variété et la vitesse dépassent les capacités des systèmes de gestion de données traditionnels. Dans le domaine médical, le Big Data englobe les millions d'images médicales, les dossiers patients et les données génomiques générées quotidiennement.

Le Big Data se caractérise par les 5V :

- **Volume** : quantité massive de données (téraoctets, pétaoctets)
- **Vélocité** : vitesse de génération et de traitement des données
- **Variété** : diversité des formats (images, textes, vidéos)
- **Véracité** : fiabilité et qualité des données
- **Valeur** : utilité des données pour la prise de décision

2.3.2 Apache Hadoop

Apache Hadoop est un framework open source conçu pour le stockage distribué et le traitement de grandes quantités de données sur des clusters d'ordinateurs. Il repose sur deux composants principaux : HDFS (Hadoop Distributed File System) pour le stockage distribué des données, et MapReduce pour le traitement parallèle.

2.3.3 Apache Spark

Apache Spark est un moteur de traitement de données distribué, conçu pour être jusqu'à 100 fois plus rapide que Hadoop MapReduce grâce au traitement en mémoire vive (RAM). Spark s'intègre parfaitement avec Hadoop et offre des bibliothèques dédiées au Machine Learning (MLlib) et au traitement de flux de données. Dans notre projet, nous utilisons PySpark, l'interface Python d'Apache Spark, pour déployer notre système de prédiction.

2.4 Machine Learning et Deep Learning

2.4.1 Machine Learning

Le Machine Learning (apprentissage automatique) est une branche de l'Intelligence Artificielle qui permet aux systèmes informatiques d'apprendre automatiquement à partir de données sans être explicitement programmés. Les algorithmes de Machine Learning identifient des patterns dans les données pour effectuer des prédictions ou des classifications.

2.4.2 Deep Learning

Le Deep Learning (apprentissage profond) est une sous-catégorie du Machine Learning basée sur des réseaux de neurones artificiels à plusieurs couches. Ces réseaux sont capables d'apprendre automatiquement des représentations hiérarchiques des données, ce qui les rend particulièrement efficaces pour le traitement d'images médicales.

2.5 Les Réseaux de Neurones Convolutifs (CNN)

Les Réseaux de Neurones Convolutifs (Convolutional Neural Networks - CNN) sont une architecture de Deep Learning spécialement conçue pour le traitement d'images. Ils sont largement utilisés en imagerie médicale pour la détection et la classification de pathologies.

Un CNN est composé de plusieurs types de couches :

- **Couches de convolution (Conv2D)** : détectent les caractéristiques locales des images (contours, textures, formes).
- **Couches de pooling (MaxPooling2D)** : réduisent la dimensionnalité tout en conservant les informations importantes.
- **Couches de normalisation (BatchNormalization)** : stabilisent et accélèrent l'entraînement.

- **Couches de Dropout** : préviennent le sur-apprentissage en désactivant aléatoirement des neurones.
- **Couches denses (Dense)** : effectuent la classification finale.

Dans notre projet, nous utilisons l'optimiseur Adam (Adaptive Moment Estimation), un algorithme d'optimisation avancé qui adapte le taux d'apprentissage pour chaque paramètre, ce qui accélère la convergence du modèle.

3. Solution Proposée

3.1 Architecture du système

Notre système de détection précoce de la maladie d’Alzheimer repose sur un pipeline complet intégrant le Big Data et le Deep Learning :

Étape	Composant	Description
1	Dataset (Kaggle)	33 984 images IRM classées en 4 catégories
2	Apache Spark (PySpark)	Chargement et analyse Big Data des images
3	Prétraitement	Normalisation, redimensionnement, augmentation
4	Modèle CNN	Classification des images IRM (4 classes)
5	Évaluation	Précision 97%, F1-score, matrice de confusion
6	Interface Gradio	Déploiement et utilisation interactive

TABLE 3.1 – Pipeline du système de détection

3.2 Dataset utilisé

Le dataset utilisé est le *Augmented Alzheimer MRI Dataset*, disponible sur Kaggle. Ce dataset contient 33 984 images IRM cérébrales réparties en 4 classes :

Classe	Nombre d’images	Pourcentage
NonDemented	9 600	28.25%
MildDemented	8 960	26.37%
VeryMildDemented	8 960	26.37%
ModerateDemented	6 464	19.02%
TOTAL	33 984	100%

TABLE 3.2 – Distribution du dataset Alzheimer MRI

Le dataset présente un léger déséquilibre entre les classes, la classe ModerateDemented étant moins représentée. Ce déséquilibre a été pris en compte dans l’évaluation du modèle en utilisant des métriques pondérées.

3.3 Prétraitement des données

Avant d'être soumises au modèle CNN, les images IRM ont subi plusieurs étapes de prétraitement :

- **Redimensionnement** : toutes les images sont redimensionnées à 128×128 pixels pour uniformiser les entrées du modèle.
- **Normalisation** : les valeurs des pixels sont normalisées entre 0 et 1 (division par 255) pour faciliter l'apprentissage.
- **Augmentation de données** : rotation (10°), zoom (20%), retournement horizontal pour augmenter la diversité des données.
- **Division du dataset** : 80% des images pour l'entraînement et 20% pour la validation.

3.4 Modèle CNN

3.4.1 Architecture du modèle

Notre modèle CNN est composé de 4 blocs convolutifs suivis d'un classificateur :

Couche	Type	Paramètres	Sortie
1	Conv2D + BatchNorm + MaxPool	32 filtres, kernel 3×3	$63 \times 63 \times 32$
2	Conv2D + BatchNorm + MaxPool	64 filtres, kernel 3×3	$30 \times 30 \times 64$
3	Conv2D + BatchNorm + MaxPool	128 filtres, kernel 3×3	$14 \times 14 \times 128$
4	Conv2D + BatchNorm + MaxPool	256 filtres, kernel 3×3	$6 \times 6 \times 256$
5	Flatten + Dense(512)	Dropout 0.5	512
6	Dense(256)	Dropout 0.3	256
7	Dense(4)	Softmax	4 classes

TABLE 3.3 – Architecture du modèle CNN

Total des paramètres du modèle : **5 242 053** paramètres entraînables.

3.4.2 Paramètres d'entraînement

Le modèle a été entraîné avec les paramètres suivants :

- **Optimiseur** : Adam avec un taux d'apprentissage de 0.001
- **Fonction de perte** : Categorical Crossentropy
- **Métrique d'évaluation** : Accuracy
- **Nombre d'epochs** : 10
- **Taille des batches** : 32
- **Environnement** : Google Colab (GPU gratuit)

3.5 Déploiement sur Hadoop via PySpark

Conformément aux exigences du projet, notre système a été déployé sur une infrastructure Big Data basée sur Apache Spark (PySpark).

3.5.1 Pipeline de déploiement

Le pipeline comprend les étapes suivantes :

- Initialisation d'une session Apache Spark.
- Chargement du dataset (33 984 images) dans un DataFrame Spark distribué.
- Analyse statistique Big Data : distribution des classes, comptage des images par catégorie.
- Application du modèle CNN via une fonction UDF (User Defined Function) Spark sur les images.
- Sauvegarde des résultats de prédiction dans Google Drive.

3.5.2 Analyse Big Data avec Spark

Apache Spark nous a permis d'analyser l'ensemble du dataset de manière distribuée :

- Nombre total d'images analysées : 33 984
- Traitement parallèle via le moteur Spark version 4.0.2
- Les prédictions sont appliquées sur toutes les images via une UDF Spark

3.6 Interface utilisateur Gradio

Afin de rendre notre système accessible aux professionnels de santé, nous avons développé une interface utilisateur interactive avec la bibliothèque Gradio. Cette interface permet :

- D'uploader une image IRM cérébrale (formats JPG, PNG, WEBP).
- D'obtenir automatiquement le diagnostic avec le niveau de confiance.
- D'afficher le niveau de risque avec un code couleur.
- De consulter une explication détaillée et des conseils médicaux adaptés.
- De visualiser les probabilités pour chacune des 4 classes.



FIGURE 3.1 – Interface Gradio — écran d'accueil



FIGURE 3.2 – Interface Gradio — résultat du diagnostic

4. Résultats et Évaluation

4.1 Résultats de l'entraînement

Le modèle CNN a été entraîné sur 10 epochs. Les résultats montrent une progression régulière de la précision au fil des epochs :

Epoch	Acc. Train	Val Acc.	Loss	Val Loss
1	57.04%	71.72%	0.9162	0.6346
2	72.94%	80.52%	0.6001	0.4511
3	81.11%	85.79%	0.4370	0.3403
4	86.23%	88.74%	0.3248	0.2737
5	88.77%	89.63%	0.2615	0.2568
6	91.02%	90.58%	0.2173	0.2333
7	92.58%	90.82%	0.1836	0.2300
8	93.68%	91.10%	0.1540	0.2524
9	94.13%	90.58%	0.1465	0.2660
10	94.90%	91.58%	0.1273	0.2385

TABLE 4.1 – Progression de la précision par epoch

Les courbes d'apprentissage montrent que le modèle apprend progressivement et n'est pas en situation de sur-apprentissage (overfitting), les courbes de validation suivant de près les courbes d'entraînement.




FIGURE 4.1 – Courbes de précision et de perte du modèle CNN

4.2 Évaluation finale du modèle

L'évaluation finale sur l'ensemble complet du dataset (33 984 images) donne les résultats suivants :

Classe	Précision	Recall	F1-Score	Support
MildDemented	0.97	0.98	0.98	8 960
ModerateDemented	1.00	1.00	1.00	6 464
NonDemented	0.98	0.95	0.96	9 600
VeryMildDemented	0.94	0.97	0.95	8 960
Moyenne	0.97	0.97	0.97	33 984

TABLE 4.2 – Rapport de classification du modèle CNN

Ces résultats sont excellents, notamment pour la classe ModerateDemented qui atteint une précision parfaite de 100%. La précision globale pondérée du modèle est de **97%**.

4.3 Matrice de confusion

La matrice de confusion confirme la haute performance du modèle. Les valeurs les plus élevées se trouvent sur la diagonale principale :




FIGURE 4.2 – Matrice de confusion du modèle CNN

— **MildDemented** : 8 755 images correctement classées sur 8 960 (97.7%)

- **ModerateDemented** : 6 455 images correctement classées sur 6 464 (99.9%)
- **NonDemented** : 9 101 images correctement classées sur 9 600 (94.8%)
- **VeryMildDemented** : 8 650 images correctement classées sur 8 960 (96.5%)

4.4 Analyse Big Data avec Spark

L'analyse du dataset via Apache Spark a fourni les statistiques suivantes :

Classe	Nombre d'images	Pourcentage
NonDemented	9 600	28.25%
MildDemented	8 960	26.37%
VeryMildDemented	8 960	26.37%
ModerateDemented	6 464	19.02%
Total	33 984	100%

TABLE 4.3 – Distribution des données analysées par Spark

4.5 Démonstration de l'interface Gradio

Lors des tests effectués avec des images IRM du dataset, le système a produit les résultats suivants :

- Image IRM saine (NonDemented) : diagnostic correct avec une confiance de 100%
- Image IRM Alzheimer léger (MildDemented) : diagnostic correct avec niveau de risque modéré et confiance de 99.84%
- Affichage du niveau de risque avec code couleur et conseils médicaux adaptés

5. Conclusion

Dans ce projet, nous avons implémenté avec succès un système de détection précoce de la maladie d'Alzheimer à partir d'images IRM cérébrales, en combinant les technologies du Big Data et du Deep Learning.

Notre système repose sur un modèle CNN entraîné sur un dataset de 33 984 images IRM provenant de la plateforme Kaggle. Le modèle atteint une précision globale de **97%** avec un F1-score de **0.97**, ce qui représente un niveau de performance professionnel pour ce type de tâche.

Le système a été déployé sur une infrastructure Big Data basée sur Apache Spark (PySpark), conformément aux exigences du module Big Data. Apache Spark nous a permis de traiter et d'analyser l'ensemble du dataset de manière distribuée et d'intégrer le modèle CNN dans un pipeline de prédiction scalable.

Une interface utilisateur interactive développée avec Gradio permet aux utilisateurs d'uploader des images IRM et d'obtenir un diagnostic automatique avec le niveau de risque et des conseils médicaux adaptés.

Bibliographie

1. World Health Organization. *Dementia Fact Sheet*. 2023. <https://www.who.int/news-room/fact-sheets/detail/dementia>
2. LeCun, Y., Bengio, Y., Hinton, G. Deep learning. *Nature*, 521, 436–444, 2015.
3. Kaggle Dataset : Augmented Alzheimer MRI Dataset. <https://www.kaggle.com/datasets/uraninjo/augmented-alzheimer-mri-dataset>
4. Apache Spark Documentation. <https://spark.apache.org/docs/latest/>
5. TensorFlow/Keras Documentation. https://www.tensorflow.org/api_docs
6. Gradio Documentation. <https://www.gradio.app/docs/>
7. Chollet, F. *Deep Learning with Python*. Manning Publications, 2017.
8. Dean, J., Ghemawat, S. MapReduce : Simplified data processing on large clusters. *Communications of the ACM*, 51(1), 107–113, 2008.